Santiago centro en PostGIS: ciudad construida y transporte público

Tarea 1 · Procesamiento Masivo de Datos · ELE051-B · USM 2026-2

Joaquín Mondaca · Vicente Hermosilla · Andrés Pérez

Fuentes y contexto. OSM Geofabrik `chile-261017.osm.pbf` (datos al 2026-10-17T20:20:51Z, sha `67705ad6`), GTFS DTPM `GTFS_20261003.zip` (versión V168, vigencia 2026-10-03 a 2026-12-31, sha `e2dded09`), DPA 2023 (`comunas_cl.sql`, sha `761e0c5c`). Bounding Box: lon -70,75..-70,52 / lat -33,52..-33,36 (**SRID 5361**, UTM 19S SIRGAS-Chile). 30 comunas tocan la caja; **13** quedan íntegras. "OSM" = mapeo voluntario; "GTFS" = declaración oficial DTPM vigente. Repositorio: `JMondacav/tarea1_v2`.

P1. Densidad de paraderos GTFS por comuna

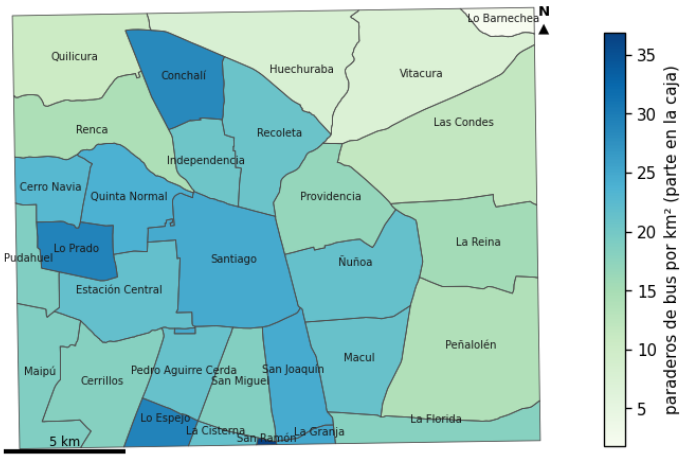
La caja concentra **6 569 paraderos de bus** en 390,3 km2 netos, con una densidad media de **17,3 par./km2**.

Comuna	km2 caja	% en caja	par./km2	salidas/día
San Ramón	0,16	3 %	**36,9**	1 560
Lo Espejo	4,04	49 %	**29,2**	34 520
Lo Prado	6,54	100 %	**29,2**	56 717
Conchalí	10,94	100 %	**28,4**	77 684
Santiago	23,18	100 %	24,7	248 276
Vitacura	26,35	92 %	7,4	62 006
Lo Barnechea	2,81	0 %	1,8	1 693

Interpretación. Lo Prado, Conchalí y Lo Espejo superan a Santiago (>28 par./km2) por alta concentración de recorridos en corredores estructurantes (Av. Independencia, El Salto, Alameda-Pajaritos). Vitacura y Lo Barnechea presentan densidades bajas debido a patrones residenciales de baja densidad. San Ramón (3 % en caja) y Lo Barnechea (0 %) presentan distorsión estadística por efecto de borde.

Plan. `GroupAggregate` sobre `comunas_sub` (129 piezas <=64 vértices, Seq Scan externo en 0,022 ms) + inner `Index Scan using paraderos_gtfs_gix` filtrando `sirve_bus AND en_caja AND ST_Intersects`. **Tiempo: 7,3 ms**. `comunas_sub_gix` marca 0 usos porque las 129 piezas van al lado externo del Nested Loop (Seq Scan más eficiente en ese volumen).

P1. Densidad de paraderos de bus (GTFS) por comuna



Datos: OSM chile-261017.osm.pbf [2026-10-17T20:20:51Z] · GTFS GTFS_20261003.zip [V168.20261003 (20261003-20261231)] · DPA 2023 · EPSG:5361

P2. Cobertura a 500 m

El **98,9 % de los 119 015 edificios** tiene paradero de bus a <=500 m en ambas fuentes. Solo **1 355 edificios** (1,1 %) están lejos de alguna fuente.

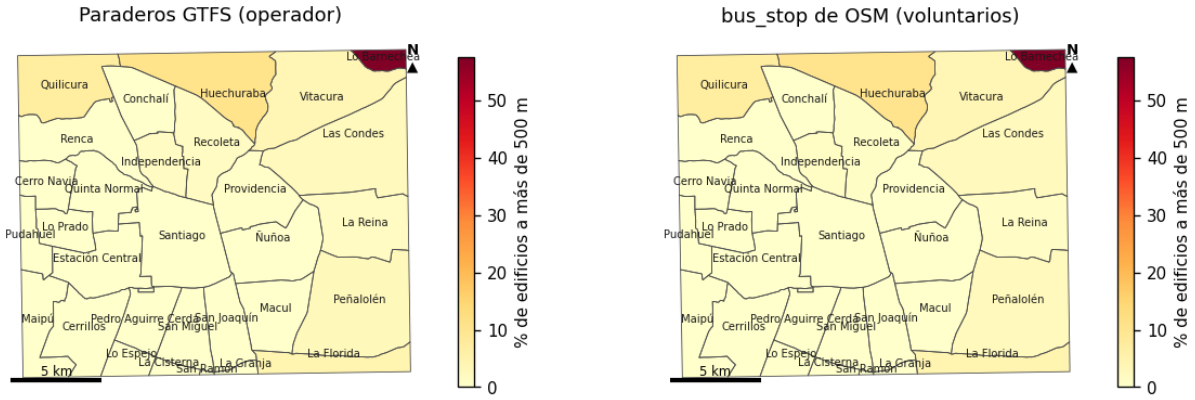
Comuna	Edif.	% lejos GTFS	% lejos OSM	solo GTFS lejos	solo OSM lejos
Lo Barnechea	78	57,7 %	57,7 %	0,0 %	0,0 %
Huechuraba	1 269	10,7 %	10,4 %	0,6 %	0,2 %
Quilicura	2 295	7,3 %	7,3 %	0,1 %	0,1 %
Recoleta	3 085	1,8 %	1,0 %	**0,9 %**	0,0 %
Providencia	12 129	0,7 %	0,1 %	**0,6 %**	0,0 %

Acuerdo global: Ambos cerca: **117 660** (98,9 %) | Lejos solo OSM: **25** (0,0 %) | Lejos solo GTFS: **215** (0,2 %) | Ambos lejos: **1 115** (0,9 %).

Interpretación. El déficit en Lo Barnechea y Huechuraba es orográfico y de baja densidad. En Recoleta y Providencia, el 0,9 % y 0,6 % "solo GTFS lejos" corresponde a paradas mapeadas en OSM pero sin servicios activos en el feed GTFS. Los 25 edificios "solo OSM lejos" corresponden a paradas no mapeadas por voluntarios en OSM. En el centro el acuerdo entre fuentes es prácticamente total.

Plan. Nested Loop Anti Join: `Parallel Seq Scan` en `edificios` (3 workers, externo) + inner `Index Scan using paraderos_gtfs_bus_gix` (parcial GiST, `st_expand(punto, 500)`). Sin índice: ~781 M comparaciones. Con índice: ~119 k accesos directos. **Tiempo: 404 ms** (paralelizado).

P2. Edificios a más de 500 m de un paradero, según la fuente



Datos: OSM chile-261017.osm.pbf [2026-10-17T20:20:51Z] · GTFS GTFS_20261003.zip [V168.20261003 (20261003-20261231)] · DPA 2023 · EPSG:5361

P3. Paraderos en una sola fuente

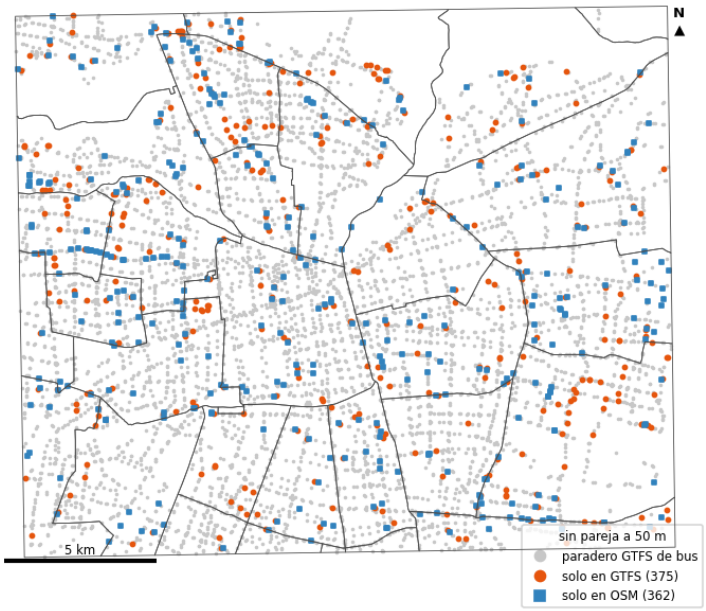
En la caja: GTFS bus **6 569** (375 sin OSM a <=50 m, **5,7 %**) | OSM bus_stop **6 572** (362 sin GTFS a <=50 m, **5,5 %**).

Sensibilidad al umbral: 20 m: 1 269 huerfanos | 50 m: 375 | 100 m: 136. Por cuartil de salidas: Q1 (2-115 salidas/día): **8,3 %** sin OSM vs Q4 (419-2 348 salidas): **4,0 %**.

Interpretación. El 5,7 % de paradas GTFS sin contraparte OSM se duplica en el cuartil de baja frecuencia (8,3 % en Q1), lo que revela subcobertura del mapeo voluntario en zonas periféricas. Los 362 nodos OSM sin GTFS corresponden a paradas sin trazados vigentes o desfase de geocodificación (el salto a 1 269 huérfanos a 20 m evidencia un offset posicional sistemático entre el poste y la calzada).

Plan. Nested Loop Anti Join: `Seq Scan` en `paraderos_gtfs` (6 569 filas, externo) + inner `Index Scan using paraderos_osm_gix` (`st_expand(geom, 50)`). Sin índice: 43 M evaluaciones `ST_DWithin`. Con índice: ~6 500 accesos. **Tiempo: 37,8 ms**.

P3. Paraderos que aparecen en una sola fuente



Datos: OSM chile-261017.osm.pbf [2026-10-17T20:20:51Z] · GTFS GTFS_20261003.zip [V168.20261003 (20261003-20261231)] · DPA 2023 · EPSG:5361

P4. Km de red de bus por comuna

Km de red unida por ruta y sentido dentro de la caja (trazados de ida y vuelta contabilizados por separado):

Comuna	km bus	rutas	km/km2
Santiago	1 117,6	149	48,2
Estación Central	522,3	78	36,3
Lo Prado	208,1	68	31,8
Providencia	394,3	80	27,3
La Granja	15,1	20	14,0
Lo Barnechea	7,7	10	2,7

Evaluación de ST_Subdivide (longitud total invariante: 8 403,2 km): Sin subdividir (30 polígonos): **475 ms** (referencia) | 256 vértices (34 piezas): 494 ms (+4 %) | 128 vértices (62 piezas): 620 ms (+31 %) | 64 vértices (129 piezas): 968 ms (+104 %) | 32 vértices (301 piezas): 1 634 ms (+244 %) | 16 vértices (749 piezas): 1 260 ms (+165 %).

Interpretación. Santiago lidera ampliamente (1 117 km) por convergencia troncal. `ST_Subdivide` resulta contraproducente: las comunas tienen geometrías simples (5 106 vértices totales); subdividirlas multiplica los pares línea-pieza y las consultas al índice sin simplificar el costo unitario de intersección.

Plan. Nested Loop: `Seq Scan` en `comunas` (30 filas, externo) + inner `Index Scan using red_ruta_gix` (**484 ms**). Con `comunas_sub` (64 vértices, 129 piezas) el tiempo asciende a **901 ms** (+86 %) por sobrecarga de accesos al índice GiST.

P5. Salud cerca de los paraderos de la ruta I09

Ruta evaluada: **I09** (473 salidas/día hábil, máxima frecuencia en la caja). Total en caja: **24 paraderos**.

Paradero (abreviado)	Establecimiento más cercano	Tipo OSM	Distancia
PI387 / Paradero 12 Pajaritos	CESFAM Clotario Blest	clinic	583 m
PI388 / Col. Sta. María de Maipú	CESFAM Clotario Blest	clinic	712 m
PI395 / Paradero 6 Pajaritos	CESFAM Santiago Occidente	clinic	145 m

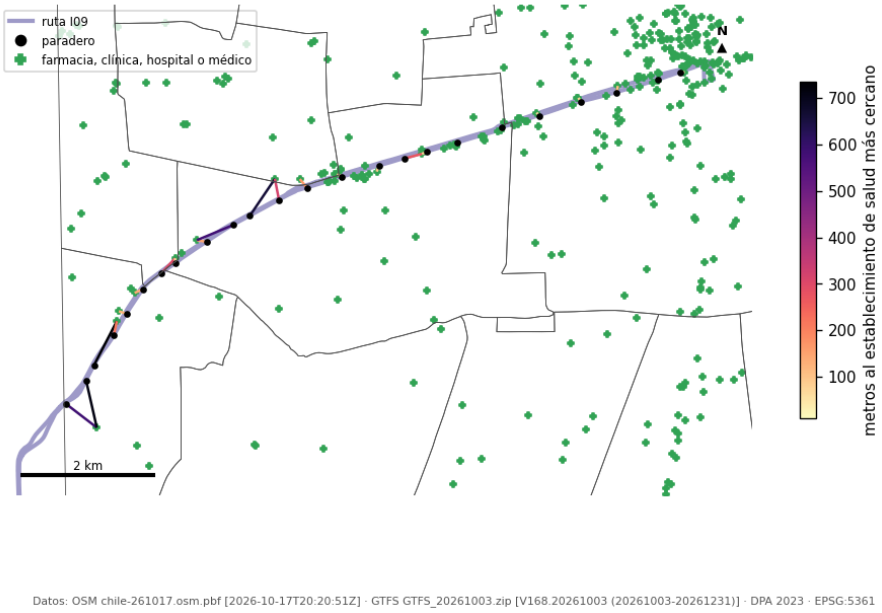
Paradero (abreviado)	Establecimiento más cercano	Tipo OSM	Distancia
PA215 / (M) La Moneda	Cruz Verde	pharmacy	10 m
PI394 / Paradero 7 Pajaritos	Farmacias Ahumada	pharmacy	75 m

Distribución: Mediana: **121 m** | Máximo: **712 m** | **79,2 % de paraderos a <=400 m**.

Interpretación. En Av. Pajaritos (poniente), los paraderos distan entre 583 m y 712 m del CESFAM más próximo, distancia crítica para usuarios vulnerables. En el eje Alameda-La Moneda, la densidad de farmacias reduce la mediana a 121 m.

Plan. Nested Loop: `Seq Scan` en `p5_paraderos` (24 filas, externo) + `Limit 1` + inner `Index Scan using amenidades_salud_gix Order By geom <-> pa.geom` (KNN sobre índice parcial GiST de salud, 56 kB). Evita ordenar las 20 983 amenidades globales. **Tiempo: 0,5 ms**.

P5. Salud más cercana a cada paradero de la ruta I09



Datos: OSM chile-261017.osm.pbf [2026-10-17T20:20:51Z] · GTFS GTFS_20261003.zip [V168.20261003 (20261003-20261231)] · DPA 2023 · EPSG:5361

P6. Hexágonos de 500 m (ciudad construida vs. red de bus)

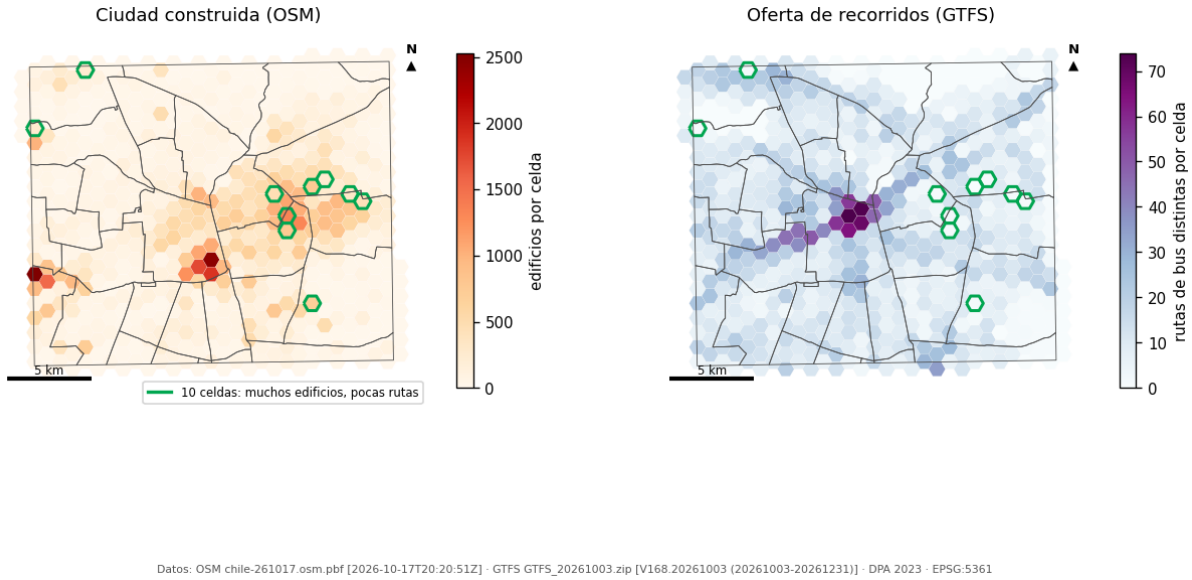
636 celdas cubren la caja: **604 con edificios**, **34 con edificios pero sin rutas**. Correlación edificios-rutas: **0,18** (desacople espacial).

Top celdas con más edificios y déficit de transporte: Celda 491 (Las Condes: 755 edif., 0 rutas; lon -70,57 / lat -33,43) | Celda 446 (Ñuñoa: 1 344 edif., 3 rutas) | Celda 445 (Ñuñoa: 765 edif., 2 rutas) | Celda 483 (Peñalolén: 702 edif., 2 rutas) | Celda 426 (Providencia: 456 edif., 1 ruta).

Interpretación. La baja correlación (0,18) confirma que la malla de buses prioriza vías troncales sobre tejido residencial interior. Las Condes oriente (celda 491, 755 edif. sin bus) y sectores de Ñuñoa evidencian celdas densas servidas únicamente por vías perimetrales. Las 34 celdas sin servicio formal representan déficit directo de cobertura.

Plan. `GroupAggregate` sobre Nested Loop: `Seq Scan` en `recorridos` (690 shapes) + inner `Index Scan using hex_gix` (GiST, 636 celdas, 690 usos). **Tiempo: 206 ms**. Sin índice: 438 840 evaluaciones completas de `ST_Intersects`.

P6. Hexágonos de 500 m: edificios frente a rutas de bus



Datos: OSM chile-261017.osm.pbf [2026-10-17T20:20:51Z] · GTFS GTFS_20261003.zip [V168.20261003 (20261003-20261231)] · DPA 2023 · EPSG:5361

P7. Pregunta propia: jerarquía vial OSM de los recorridos de bus

Pregunta y método: ¿Por qué jerarquías viales de OSM circulan los buses del GTFS y cuánto no coincide con calles mapeadas? Muestreo cada 50 m de rutas GTFS ponderado por salidas diarias, asociado vía KNN (<=20 m) al índice parcial `calles_bus_gix`.

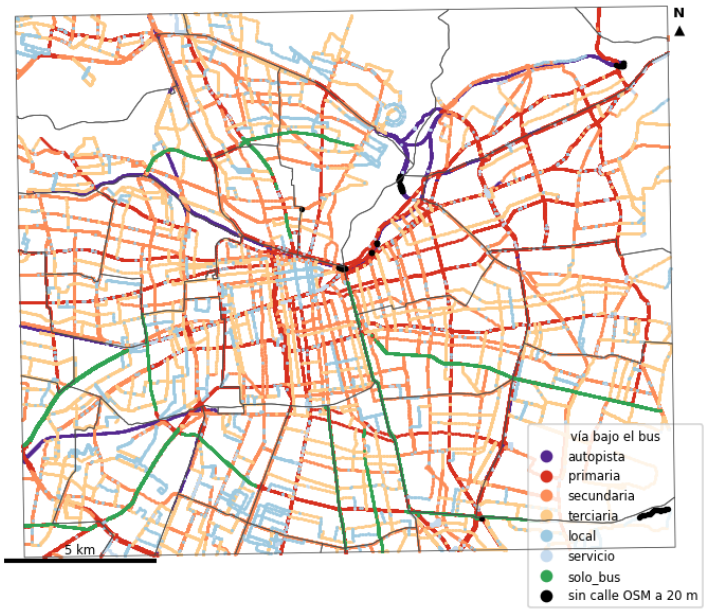
Jerarquía vial OSM	km de red	bus-km/día	% bus-km
Primaria	2 891,7	286 511	**36,8 %**
Secundaria	2 180,6	202 250	**26,0 %**
Terciaria	1 439,5	131 831	16,9 %
Solo bus (carril exclusivo)	737,3	68 973	8,9 %
Autopista	609,9	42 591	5,5 %
Local	400,4	36 494	4,7 %
Servicio	93,6	8 808	1,1 %
Sin calle OSM a <=20 m	6,7	501	**0,1 %**

Rutas con mayor tramo sin calle OSM (>=2 km en caja): D17 (5,7 %), C26c (3,5 %), 117c (3,1 %).

Interpretación. El 62,8 % del bus-km diario discurre por vías primarias y secundarias, validando el modelo troncal del sistema RED. El 8,9 % en `solo_bus` refleja carriles exclusivos adecuadamente etiquetados en OSM. El residual de 0,1 % sin calle se debe a obras recientes, túneles o desfase GPS, certificando una completitud sobresaliente de OSM en corredores de transporte.

Plan. Nested Loop Left Join: `Seq Scan` en `p7_muestras` (2 000 filas, externo) + `Limit 1` + inner `Index Scan using calles_bus_gix Order By geom <-> muestras.geom, Filter: ST_DWithin(geom, punto, 20)`. El índice parcial filtra 30 007 vías peatonales/no vehiculares (~30 % del grafo vial). **Tiempo: 32,8 ms**.

P7. Por qué vías de OSM pasan los recorridos de bus



Datos: OSM chile-261017.osm.pbf [2026-10-17T20:20:51Z] · GTFS GTFS_20261003.zip [V168.20261003 (20261003-20261231)] · DPA 2023 · EPSG:5361

Decisiones del pipeline

Infraestructura y reproducibilidad. PostGIS 16-3.4 oficial sin capas personalizadas. Soporte (GDAL, osmium, psql, Python) en contenedor Ubuntu 24.04 (`herramientas`). Sincronización mediante healthcheck `pg_isready`. Carga automatizada íntegra en **139 s**. El procesamiento de DPA utilizó base temporal para no sobreescribir el esquema principal (`paso_dpa.sh`). Detección elástica de archivos de entrada (`GTFS*.zip`, `chile*.osm.pbf`).

Proyección y caja territorial. SRID 5361 (UTM 19S SIRGAS-Chile). Datos crudos preservados en `fuente_*` (4326/texto). Transformación única en `{osm,gtfs,dpa}_derivar.sql`. Densificación de la caja previa a proyectar. `ST_DWithin(geom, punto, 500)` garantiza radios euclidianos de 500 m exactos.

Calidad geométrica y reparaciones OSM. 16 multipolygons inválidos (todos autointersecciones de anillo, 0 líneas inválidas) corregidos con `ST_MakeValid + ST_CollectionExtract(..., 3)`: **10 edificios reparados**, **0 descartados**. Punto interior: `edificios.punto = ST_PointOnSurface(geom)` asegura inclusión dentro del polígono (el centroide cae fuera en formas en L o cóncavas).

GTFS y modelado de red. `stop_times.txt` (**1 098 529 filas**) cargado en streaming vía `COPY FROM STDIN`. Frecuencias expandidas para miércoles hábil representativo (`wednesday=1`, 14 542 tramos de `frequencies.txt` convertidos mediante `ceil((end-start)/headway)`): **68 834 salidas/día**. `red_ruta` consolida los shapes por ruta-sentido con `ST_Union` (grilla 1 m), evitando duplicar tramos compartidos: 14 932 km brutos de shapes vs. **12 357 km** de red unificada (-17 %).

Auditoría de índices (`pg_stat_user_indexes`). 32 índices en esquema `stgo`. Mayor frecuencia de uso: `calles_bus_gix` (169 191 usos), `paraderos_osm_gix` (151 860), `paraderos_gtfs_gix` (125 845), `edificios_punto_gix` (765). Índices con 0 usos: `amenidades_gix` y `calles_geom_gix` no fueron requeridos al operar sobre los parciales especializados `amenidades_salud_gix` y `calles_bus_gix`; `edificios_geom_gix` fue omitido al trabajar con `edificios.punto`; `comunas_caja_gix` y `comunas_sub_gix` no se ejecutaron porque el planificador selecciona Seq Scan sobre 30 y 129 filas. Todos poseen justificación técnica. En `ST_Subdivide`, la invariancia métrica (8 403,2 km en las 6 ejecuciones) certifica consistencia geométrica absoluta.